

Small Language Models Especializados para Tarefas Específicas

Um Estudo de Caso em NER no Diário Oficial do DF

Pedro Igor Oliveira Silva

Universidade de Brasília — 2026

 Motivação

 O Problema / DODF

 Hipóteses H1 e H2

 Dataset e Divisão

 Método (Prompt + LoRA/DoRA)

 Protocolo de Avaliação

 Resultados H1 (NER)

 Resultados H2 (Esquecimento)

 Discussão

 Conclusão


Motivação: Por que SLMs especializados?

⚠ Problema com LLMs via API

- Custo **por chamada** a cada documento
- Capacidade geral **ociosa** em tarefas repetitivas
- Dependência de API externa / internet

✅ Oportunidade com SLMs locais

- Custo **marginal** quase zero pós-treino
- Inferência **local** sem GPU potente
- Evidência: *State of AI Report 2025*



A literatura de SLM segue duas linhas, **roteamento** e **especialização**; este trabalho fica na **especialização**: um SLM incapaz na tarefa que o fine-tuning torna competente.

O Problema: NER no Diário Oficial do DF

DODF

- Atos jurídico-administrativos publicados **todo dia útil**
- Nomeações, exonerações, cessões, substituições...
- Texto muito **templatizado**
- Hoje lido **manualmente**

Entidades a extrair

NOME · MATRÍCULA · CARGO
ÓRGÃO · PROCESSO · VIGÊNCIA...


Trecho de ato (Nomeação):

... nomear MARIA SILVA [NOME],
mat. 1234567 [MATR.],
para o cargo de
Analista de PP [CARGO]
na Sec. de Educação [ÓRGÃO]...

Corpus: UnB-KnEDLe / DODF
Único corpus anotado
gold standard público
neste domínio

H1 — Ganho de NER

O Qwen3-4B **especializado** (LoRA/DoRA) supera o mesmo modelo em **zero-shot** no F1-score de NER.



H2 — Esquecimento Catastrófico

O fine-tuning **altera** as capacidades gerais, medidas em cinco benchmarks MCQ.

Base $\rightarrow$ Fine-tuned
 Δ benchmark = ?

F1-score: média harmônica entre **precision** (fração das entidades previstas que estão corretas) e **recall** (fração das entidades reais que foram encontradas). Penaliza modelos que acertam muito mas perdem entidades, ou que encontram tudo mas com muitos falsos positivos.

SLM: **Qwen3-4B** (Alibaba, Apache 2.0) — PT-BR, 4B parâmetros, 32k tokens


Características

- 11 tipos de ato
- ~9.778 documentos
- Anotação manual **gold standard**
- Formato CoNLL, BIO tagging

✂ Divisão 70/15/15

- Por **documento** (evita leakage)
- Estratif. por **tipo de ato**
- Deduplicação por hash de texto
249 grupos idênticos cruzariam splits
(7,9% do corpus)

Treino: 6.844 | Val: 1.469 | Teste: 1.465



Dataset: Gold Standard e Instâncias GNER

📄 Texto BIO (gold)

nomear (0)
MARIA (B-NOME)
SILVA (I-NOME)
mat. (0)
123456 (B-MATR)
para (0) o (0)
cargo (0) de (0)
Analista (B-CARGO)
de (I-CARGO)
PP (I-CARGO)
na (0)
Sec. (B-ÓRGÃO)
Educação (I-ÓRGÃO)

✅ Instância positiva

Extrai **NOME**:
nomear (0)
MARIA (B-NOME)
SILVA (I-NOME)
mat. (0) 123456 (0)
para (0) o (0)
cargo (0) de (0)
Analista (0) de (0)
PP (0) na (0)
Sec. (0) Educação (0)

Entidade presente ⇒ tags B/I corretas

❌ Instância negativa


Extrai **PROCESSO**:
nomear (0)
MARIA (0)
SILVA (0)
mat. (0) 123456 (0)
para (0) o (0)
cargo (0) de (0)
Analista (0) de (0)
PP (0) na (0)
Sec. (0) Educação (0)

Entidade ausente ⇒ tudo (O) ⇒ reduz FP

Anotação manual gold standard

43% das instâncias são negativas (GNER): o modelo aprende *quando não extrair*. Reduz falsos positivos sem precisar de heurísticas.

Pipeline Experimental



Formato de Prompt: Instruction-Tuning (GNER)

📄 Estrutura: um prompt por entidade

Extraia todas as ocorrências da entidade [NOME] do texto.

Reproduza o texto inteiro, token a token, e após cada token anexe entre parênteses o rótulo BIO:

- B-[NOME] no 1º token da entidade;
- I-[NOME] nos tokens seguintes;
- (0) fora da entidade.

Formato: token1(0) token2(B-[NOME])...

nomear Maria Silva para exercer...

nomear(0) Maria(B-NOME) Silva(I-NOME) para(0)...

! Instâncias negativas (GNER)

Entidade **ausente** ⇒ resposta com (0)
em todos os tokens ⇒ **reduz falsos positivos**

📊 Composição do conjunto de treino



- 57% Positivas (entidade presente)
- 43% Negativas (ausente)

87.536 registros no treino

18.737 no conjunto de teste

⚙️ LoRA

Congela W_0 , aprende $\Delta W = BA$ com $r \ll \min(d, k)$

Inferência: $W_0 + BA$ — sem latência extra

⚙️ DoRA

Decompõe pesos em **magnitude** + **direção**

Adapta a direção via LoRA; treina a magnitude à parte

⚙️ Configuração do experimento

Posto	$r=8$, $\alpha=16$, alvo Q+V
Params. trein.	LoRA: 2,9M / DoRA: 3,1M ($<0,08\%$)
Otimizador	AdamW, LR 2×10^{-4} , linear
Épocas	3, batch de 16 exemplos por vez
Precisão	bf16 (sem QLoRA necessário)

📈 Convergência (logs de treino):

Época	eval_loss	acc. token
1	0,221	0,943
2	0,218	0,945
3	0,223	0,945

Mínimo na época 2; época 3 sobe enquanto acurácia estabiliza $\Rightarrow$ 4ª época aumentaria overfitting sem ganho real.


🔍 Varredura de posto (validação):

Posto	Params.	F1	Δ
$r=4$	1,5M (0,04%)	0,806	-0,017
$r=8$	2,9M (0,07%)	0,823	ref.
$r=16$	5,9M (0,15%)	0,818	-0,005*

*IC 95% cruza zero, sem ganho real

$\Rightarrow$ **$r=8$ selecionado** para o teste

LoRA: Atualização de Baixo Posto



2560×4096

2560×8

8×4096
($r \times k$)

($d \times k$)

($d \times r$)

$r=8 \ll 2560 \rightarrow 10,5M \rightarrow 53K$
params ($\approx 200 \times$ menor, por camada)

$$W_{\text{out}} = W_0 + \underbrace{BA}_{\Delta W}$$

ex.: q_proj — total Q+V $\times$ 32 camadas: 2,9M params

DoRA: Magnitude + Direção

Decompõe W coluna a coluna:

$$W = \underbrace{\|W\|_c}_m \cdot \underbrace{\frac{W}{\|W\|_c}}_v$$

Fine-tuning DoRA:

$$W' = m \cdot \frac{W_0 + BA}{\|W_0 + BA\|_c}$$

m : magnitude (treinável)

BA : direção via LoRA

DoRA desacopla *magnitude* e *direção* do peso.
LoRA ajusta ambas de forma acoplada via $\Delta W = BA$.

NER — segeval (H1)

- F1 por **entidade** (chunk), não por token
- Modo **strict** (IOB2): span + tipo exatos
- Mesmo parser para **todos** os modelos
- IC 95% por **bootstrap** (1000 reamostras)

Benchmarks MCQ (H2)

MMLU	Conhec. geral (57 domínios)
HellaSwag	Senso comum / coerência
ARC-Easy	Raciocínio científico
ARC-Chall.	Raciocínio avançado
WinoGrande	Inferência contextual

Modelos comparados

- ➊ **Zero-shot:** Qwen3-4B sem treino
- ➋ **Few-shot 1:** 1 exemplo no contexto
- ➌ **Few-shot 3:** 3 exemplos no contexto
- ➍ **DoRA $r=8$:** fine-tuned
- ➎ **LoRA $r=8$:** fine-tuned (**principal**)
- ➏ **BERTimbau base 110M** (*ref.*)
- ➐ **BERTimbau large 335M** (*ref.*)

i **BERTimbau:** referência do estado da arte do domínio, treinado nos mesmos splits sem viés de dados.

seqeval Strict: O que Conta como Acerto?

Gold: MARIA (B-NOME) SILVA (I-NOME) 1234567 (B-MATR) para (0)

✓ TP

MARIA (B-NOME)
SILVA (I-NOME)

Span **exato** +
tipo **correto**

✗ FN+FP

MARIA (B-NOME)
(SILVA *ausente*)

Span **parcial**
= erro total

✗ FN+FP

MARIA (B-CARGO)
SILVA (I-CARGO)

Tipo **errado**
= erro total

✗ FP

SILVA (B-NOME)
mat. (I-NOME)


Span **inventado**
= falso positivo

Regra strict (IOB2): span correto $\Leftrightarrow$ B-TIPO exato no início + I-TIPO em cada token seguinte. Um único token divergente **derruba o acerto do chunk inteiro**. Um I-TIPO sem B-TIPO anterior é inválido e também penalizado.

$$F_1 = \frac{2 TP}{2 TP + FP + FN}$$
 calculado sobre entidades (chunks), não sobre tokens individuais.

IC 95% por bootstrap com 1000 reamostras.

Resultados H1: NER no Conjunto de Teste



* Zero-shot responde quase sempre em prosa; o parser IOB2 extrai quase nenhuma entidade ($F1 \approx 0,02$).

H1 confirmada: LoRA +0,800 vs zero-shot
IC 95%: [+0,793; +0,807] — inteiramente positivo

Por que o Zero-shot Obteve $F1 \approx 0,02$?

Instrução real enviada ao modelo

Extraia todas as ocorrências da entidade nome do texto.

Reproduza o texto inteiro, token a token (separados por espaço), na mesma ordem e sem omitir nenhum token. Logo após cada token, anexe entre parênteses, sem espaço, o seu rótulo BIO:

- B-nome no primeiro token de cada ocorrência da entidade nome;
 - I-nome nos demais tokens da mesma ocorrência;
 - O em todo token que não pertence à entidade.
- Formato esperado: token1(O) token2(B-nome) token3(I-nome) token4(O)

CONCEDER abono de permanencia ao servidor VALDIR MOREIRA DA SILVA matricula 27.651-0 no cargo de Auditor Fiscal de Atividades Urbanas Classe Especial Padrao V do Quadro de Pessoal do Distrito Federal de acordo com o artigo 3o da EC no 47 de 05 de julho de 2005 com amparo na Decisao no 20/2012 TCDF ...

✗ Saída real (Qwen3-4B zero-shot)

“A entidade **nome** não foi explicitamente mencionada no texto fornecido. No entanto, o servidor referenciado é **Valdir Moreira da Silva...**”

⇒ resposta em prosa livre

⇒ nenhuma tag IOB2 neste exemplo

Q O que o parser IOB2 espera:

... ao (O) servidor (O)

VALDIR (B-nome) MOREIRA (I-nome) DA (I-nome) SILVA (O) matricula (O) 27.651-0 (O) ...

✗ Mesmo com instrução de formato, modelo responde em prosa — nenhum token no padrão TOKEN (TAG)

✗ Parser não extrai entidades ⇒ $F1 \approx 0,02$

Análise de $\Delta F1$ com Intervalos de Confiança (95%)

Comparação	$\Delta F1$	IC 95%
LoRA vs zero-shot	+0,800	[+0,793;+0,807]
3-shot vs zero-shot	+0,345	[+0,337;+0,353]
LoRA vs 3-shot	+0,455	[+0,447;+0,463]
DoRA vs LoRA	+0,003	[−0,001;+0,008]
LoRA vs BERTb. base	−0,041	[−0,046;−0,036]
LoRA vs BERTb. large	−0,047	[−0,052;−0,041]

Escala monotônica

0,02 (zero-shot) < **0,25** (1-shot)
< **0,37** (3-shot) < **0,82 (LoRA)**

Treinar os pesos $\gg$ exemplos no contexto.


DoRA empata

Diferença **dentro do IC** (cruza zero).
Sem ganho que pague o custo por passo maior $\Rightarrow$ LoRA preferível.


BERTimbau

~ 4 pp acima do SLM. A diferença aumenta nos atos de **baixo recurso**.

F1 por Tipo de Ato — Modelos Seleccionados (Teste)



Resultados H2: Esquecimento Catastrófico



Bench.	Base	ΔL	ΔD
MMLU	68,4%	-3,2	-3,3
HellaSwag	68,3%	+0,5	+1,2
ARC-Easy	78,4%	-6,2	-5,5
ARC-Chall.	54,1%	-4,8	-3,2
WinoGrande	65,8%	-4,7	-4,8


⚠ H2 confirmada: houve alteração

Queda de até **6,2 pp** (ARC-Easy).
HellaSwag **subiu** +0,5 pp. H2 mede
se e quanto altera, não assume degradação.

LoRA atenua, mas **não elimina**.

IC 95% abaixo de zero em 4 dos 5 benchmarks.

Discussão: O Trade-off H1 × H2



i BERTimbau ≈ 4 pp acima do LoRA. Distância maior nos atos de **baixo recurso**.

⚖️ DoRA: empata com o LoRA em NER e degrada de forma comparável. Expressividade extra não rende no domínio templatizado.

! Limitações

1 Desequilíbrio de classes

Atos com <50 docs: F1 instável, análise qualitativa

2 Escopo da avaliação

Só MCQ; sem LLM de maior porte por indisponibilidade de hardware

A Trabalho Futuro

- > 🗄️ Comparação com LLM de grande porte (GPT-4, Llama 70B...)
- > 📈 Investigar gap decoder/encoder nos atos de baixo recurso
- > 🗝️ Mitigação do esquecimento: auto-destilação, EWC, replay de dados gerais
- > 🌱 Ampliar dados para atos raros

O que foi feito

- Especialização do **Qwen3-4B** com LoRA/DoRA no corpus UnB-KnEDLe (DODF)
- Protocolo robusto: divisão por doc + deduplicação
- Avaliação NER strict + IC 95% bootstrap
- Medição de esquecimento em 5 benchmarks



H1 confirmada: 0,02 $\rightarrow$ 0,82 com LoRA



H2 confirmada: queda de até 6,2 pp; IC 95% <0 em 4/5



DoRA: empata com LoRA; sem vantagem



BERTimbau: +4 pp

Especializar um SLM *vale a pena* frente ao uso genérico (tarefas gerais). F1 0,82 confirma a viabilidade levantada pela revisão da literatura (custo marginal ≈ 0). Mas o ganho na tarefa vem acompanhado de custo real em capacidades gerais.

- ❶ State of AI, "State of AI Report 2025," 2025. <https://www.stateof.ai/>
- ❷ P. Belcak et al., "Small language models are the future of agentic AI," *arXiv:2506.02153*, 2025.
- ❸ G. M. C. Guimarães et al., "Legal document segmentation and labeling through named entity recognition approaches," *J. Inf. Data Manag.*, vol. 15, no. 1, pp. 123–131, 2024.
- ❹ UnB-KnEDLe Project, "KnEDLe datasets: DODF atos de pessoal (gold standard NER corpus)," GitHub, 2022. <https://github.com/UnB-KnEDLe/datasets>
- ❺ Qwen Team, Alibaba Cloud, "Qwen3 technical report," *arXiv:2505.09388*, 2025.
- ❻ E. J. Hu et al., "LoRA: Low-rank adaptation of large language models," in *Proc. ICLR*, 2022.
- ❼ S.-Y. Liu et al., "DoRA: Weight-decomposed low-rank adaptation," in *Proc. ICML*, 2024.
- ❽ S. Luo et al., "An empirical study of catastrophic forgetting in large language models during continual fine-tuning," *arXiv:2308.08747*, 2023.
- ❾ J. Zhang et al., "2INER: Instructive and in-context learning on few-shot named entity recognition," in *Findings of EMNLP*, pp. 3940–3951, 2023.
- ❿ Y. Ding et al., "GNER: Generative named entity recognition with instructions," in *Findings of ACL*, 2024.
- ⓫ S. Mayhew et al., "Universal NER: A gold-standard multilingual named entity recognition benchmark," in *Proc. NAACL*, 2024.
- ⓬ T. Dettmers et al., "QLoRA: Efficient finetuning of quantized LLMs," in *Proc. NeurIPS*, 2023.
- ⓭ L. Tunstall, L. von Werra, and T. Wolf, *Natural Language Processing with Transformers*. O'Reilly Media, 2022.
- ⓮ H. Nakayama, "sequeval: A Python framework for sequence labeling evaluation," GitHub, 2018. <https://github.com/chakki-works/sequeval>
- ⓯ F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT models for Brazilian Portuguese," in *Proc. BRACIS*, pp. 403–417, 2020.
- ⓰ D. Hendrycks et al., "Measuring massive multitask language understanding," in *Proc. ICLR*, 2021.
- ⓱ R. Zellers et al., "HellaSwag: Can a machine really finish your sentence?" in *Proc. ACL*, 2019.

- 18 P. Clark et al., "Think you have solved question answering? Try ARC, the AI2 reasoning challenge," *arXiv:1803.05457*, 2018.
- 19 K. Sakaguchi et al., "WinoGrande: An adversarial Winograd schema challenge at scale," in *Proc. AAAI*, 2020.
- 20 L. Gao et al., "A framework for few-shot language model evaluation (lm-evaluation-harness)," EleutherAI, 2023.
<https://github.com/EleutherAI/lm-evaluation-harness>
- 21 Z. Yang et al., "Self-distillation bridges distribution gap in language model fine-tuning," in *Proc. ACL (Long Papers)*, pp. 1028–1043, 2024.

Obrigado!

Perguntas?

Pedro Igor Oliveira Silva

`pedro.igor@aluno.unb.br`

Universidade de Brasília — 2026

✖ Por que não ONNX/TensorRT?

Reduz memória de **inferência**, mas não de treino. O que importava aqui era o fine-tuning iterativo; a quantização relevante para isso seria NF4/QLoRA, que acabou desnecessária (treino coube em bf16).

✖ Por que não MoE (*Mixture of Experts*)?

Requer volume de dados suficiente *por especialista*. O corpus DODF tem atos com apenas 22 documentos (Tornado_Sem_Efeito_Apo). O MoE não tem o que especializar nesses casos.

✖ Por que não RAG (*Retrieval-Augmented Generation*)?

RAG agrega valor quando a resposta depende de conhecimento *externo* a recuperar. Os atos do DODF são templatizados e autocontidos: a entidade a extrair já está na própria sentença. Não há nada a recuperar.

Essas exclusões delimitam o porquê de recair sobre fine-tuning de baixo posto de um único SLM.

Qwen3-4B (LoRA/DoRA)

- GPU **AMD MI250** (cluster HPC)
- Precisão **bf16**
- QLoRA **não foi necessário** pois a VRAM foi suficiente
- Treino: 3 épocas, batch efetivo 16

Inferência pós-treino:
roda em hardware de consumidor
(sem GPU potente)

BERTimbau (base e large)

- GPU **T4** (Google Colab)
- Precisão **fp16** (T4 não suporta bf16)
- 5 épocas, batch 32, lr 2×10^{-5}
- Comprimento máx. 512 tokens

Encoder é **mais leve**
de operar que o decoder
(reforça o argumento de custo)



Strict (métrica canônica — H1)

- Span de início e fim **exatos**
- Tipo de entidade **correto**
- Esquema **IOB2 válido** (argumento `scheme=IOB2` obrigatório)
- Mais rigoroso: B sem I anterior = erro



Default

- Mesmo critério de span e tipo
- **Tolerante** a inconsistências de esquema (I sem B anterior aceito)
- Ligeiramente mais alto que strict
- Modo padrão de trabalhos antigos



Por que reportar *strict*?

O modo *strict* é mais transparente sobre o quão bem o modelo produz o esquema BIO correto. Em NER generativo, em que a saída é texto e pode conter inconsistências de esquema (I-TIPO sem B-TIPO anterior), usar *strict* é mais honesto: penaliza predições malformadas que o *default* aceitaria. Todos os modelos passam pelo mesmo parser, garantindo comparação justa.